



Licenciatura en Ciencias del Comportamiento
Ciencia de Datos

Trabajo Práctico N° 2
HISTOGRAMAS, KERNELS & MÉTODOS NO SUPERVISADOS USANDO LA EPH

Autores

Facundo Tomás Villegas Leiva

Clara Schmukler

Sofía Abril Cortada Conti

Prof. Magistral

María Noelia Romero

Prof. Tutorial

Ignacio Anchorena


Link a repositorio de GitHub

<https://github.com/cschmukler/Ciencia-de-Datos---Grupo-11.git>

Semestre de Primavera 2025

Parte I: Creación de variables, histogramas, kernels y resumen de la base de datos final


1. Histograma de variable edad (Panel A) y Distribución de kernels para los pobres y no pobres (Panel B)



El histograma del Panel A muestra que la distribución de edades está relativamente concentrada en los primeros 40 años, con un mayor número de observaciones en la infancia y juventud, y luego va disminuyendo progresivamente a medida que aumenta la edad. En el Panel B, las curvas de densidad evidencian que la población pobre se concentra principalmente en edades tempranas, mientras que la no pobre presenta menor densidad en estas edades y una distribución algo más extendida hacia la adultez. En conjunto, los gráficos sugieren que la pobreza está más asociada a los grupos jóvenes de la población, mientras que en los adultos mayores la proporción relativa de no pobres es más alta.

2. La variable educ, que mide los años de educación formal, presenta un promedio de 9,63 años con una desviación estándar de 4,38. El mínimo es 0 (sin educación) y el máximo 18 (educación superior completa), mientras que la mediana es 10 años, lo que indica que al menos la mitad de la población alcanzó hasta el nivel secundario. Estos resultados muestran una dispersión amplia, con una parte de la población que no accedió a la educación formal y otra que logró estudios universitarios. En conjunto, el promedio cercano a 10 refleja que gran parte de la muestra se concentra en torno al secundario completo.

3. Histograma de ingreso total familiar (Panel A) y Distribución de ingresos por pobreza (Panel B)



El histograma del Panel A muestra que la distribución del ingreso familiar total en pesos de 2025 es altamente asimétrica, con la mayoría de los hogares concentrados en ingresos bajos y una larga cola hacia la derecha por algunos pocos con ingresos muy elevados. La línea de pobreza se ubica en valores bajos dentro de la distribución, lo que evidencia que una gran proporción de hogares se encuentra en situación vulnerable. En el Panel B, las densidades indican que los hogares pobres se concentran casi exclusivamente en torno a la línea de pobreza, mientras que los no pobres presentan una distribución desplazada hacia la derecha. En conjunto, los gráficos reflejan una marcada desigualdad en los ingresos familiares, con la mayoría de los hogares cercanos al umbral de pobreza y pocos con niveles de ingreso significativamente superiores.


4. La variable horastrab presenta un promedio de 15,95 horas semanales con una desviación estándar de 22,39, un mínimo de 0 y un máximo de 84 horas. La mediana es 0, lo que indica que al menos la mitad de los jefes de hogar no registró horas trabajadas en la semana de referencia. Sin embargo, entre quienes sí trabajan, el percentil 75 alcanza 35 horas, reflejando jornadas de dedicación significativa. En conjunto, los resultados muestran una fuerte heterogeneidad, con muchos jefes de hogar fuera del mercado laboral y otros con cargas horarias elevadas.

5. Tabla 1. Resumen de la base final para la región Patagónica

	2005	2025	Total
Cantidad observaciones	3229	5359	8588
Cantidad de observaciones con NAs en la variable "Pobre"	23	1202	1225
Cantidad de Pobres	575	865	1440
Cantidad de No Pobres	2631	3292	5923
Cantidad de variables limpias y homogeneizadas	171	171	171

Parte II: Métodos No Supervisados


1. Matriz de correlaciones - Patagonia (2005 y 2025)



La matriz de correlaciones muestra una fuerte relación positiva entre edad y edad2 (0,96), lo que refleja que ambas variables contienen información redundante. Se observa una correlación negativa entre edad y miembros del hogar (-0,40), indicando que los hogares con jefes más jóvenes tienden a ser más numerosos. La educación presenta asociaciones positivas pero débiles tanto con el ingreso total familiar (0,12) como con las horas trabajadas (0,15), lo que sugiere una influencia moderada. En general, las correlaciones son bajas, lo que implica que la mayoría de las variables capturan dimensiones relativamente independientes.


A. PCA

2. Gráfico de dispersión de PCA




El gráfico de PCA muestra que la mayoría de los hogares, tanto en 2005 como en 2025, se concentran cerca del origen, lo que indica patrones comunes en las variables analizadas. Sin embargo, en 2025 se observa una mayor dispersión, especialmente en el segundo componente, reflejando una mayor heterogeneidad en las condiciones socioeconómicas respecto de 2005. A pesar de esta diferencia, existe un solapamiento importante entre ambos años, lo que sugiere que la estructura general de los datos se mantiene en el tiempo. En conjunto, los dos primeros componentes permiten visualizar tanto similitudes como cambios en la variabilidad de los hogares entre ambos períodos.

3. Gráfico de loadings del PCA



El gráfico de loadings del PCA muestra que en el primer componente (PC1) las variables con mayor peso son edad y edad2, ambas en la misma dirección, mientras que miembros del hogar carga en sentido opuesto, reflejando la relación inversa entre edad y tamaño del hogar. En el segundo componente (PC2) destacan educación y horastrab, junto con el ingreso familiar, todos con cargas positivas, lo que indica que este eje está asociado principalmente a características laborales y de capital humano. En conjunto, el PC1 captura sobre todo la dimensión demográfica, mientras que el PC2 refleja diferencias en educación, trabajo e ingresos.

4. Scree plot del PCA con 6 componentes




El scree plot muestra que el primer componente explica cerca del 40% de la varianza y el segundo alrededor del 20%, mientras que los siguientes aportan valores mucho menores. Con los dos primeros componentes se concentra aproximadamente el 60% de la varianza total y con tres se alcanza cerca del 75%. A partir del cuarto componente, la ganancia adicional de información es reducida. En conjunto, esto indica que los dos primeros componentes son suficientes para capturar la mayor parte de la estructura de los datos.

B. Cluster

5. Cluster k-medias:


a)

Cluster k-medias con k=2




Con $k=2$, el algoritmo forma dos grupos principales basados en la edad² y el ingreso familiar. Sin embargo, la separación no coincide exactamente con la condición de pobreza, ya que los clusters reflejan más bien una división general entre ingresos bajos y altos, sin tomar la línea de pobreza como referencia.

Cluster k-medias con k=4



Con $k=4$, los clusters capturan mayor heterogeneidad dentro de la población, distinguiendo subgrupos según combinaciones de edad e ingreso. Aun así, la separación entre pobres y no pobres no es precisa, porque se generan divisiones internas que no necesariamente corresponden al umbral de pobreza.


Cluster k-medias con $k=10$



Con $k=10$, los clusters segmentan a la población en múltiples grupos más pequeños, lo que permite representar distintos perfiles socioeconómicos (por ejemplo, jóvenes con ingresos bajos, adultos con ingresos medios, hogares de mayor edad con ingresos altos, etc.). No obstante, esta granularidad sigue sin alinear los grupos directamente con la clasificación binaria de pobres y no pobres.


Finalmente podemos decir que el algoritmo de k-medias no logra separar de forma adecuada a las personas pobres y no pobres en la región. Los clusters reflejan patrones de dispersión de ingresos y edad, pero no se corresponden con la definición socioeconómica basada en la línea de pobreza.

b) Gráfico método del codo - KMeans



El gráfico del método del codo muestra una caída pronunciada de la inercia hasta alrededor de $k=3$, punto a partir del cual las mejoras adicionales en la reducción de la disimilitud son mucho menores. Esto indica que el número óptimo de clusters para la región sería $k=3$. Sin embargo, esta cantidad de grupos no permite distinguir de manera directa a los hogares pobres de los no pobres, ya que el algoritmo no utiliza la línea de pobreza como criterio de clasificación. En cambio, los clusters identificados reflejan diferentes clases socioeconómicas en función de combinaciones de edad e ingresos.

6. Dendrograma - Clustering jerárquico (Ward)



Un dendrograma es un gráfico que representa cómo se van agrupando las observaciones en un análisis de clustering jerárquico. Cada individuo comienza como un grupo separado y, a medida que aumenta la similitud, los grupos se van fusionando hasta formar clusters más grandes. En el eje vertical se muestra la distancia o disimilitud a la que se producen las uniones, mientras que en el eje horizontal aparecen las observaciones o grupos ya formados. De esta manera, el dendrograma permite visualizar la estructura jerárquica de los datos y decidir a qué altura “cortar” el árbol para definir el número de clusters. Cuanto más alta es la unión, más diferentes eran los grupos antes de juntarse. Por ejemplo, un corte alrededor de una distancia = 100 daría lugar a 3 o 4 clusters principales.